



# MÉTRICAS DE EVALUACIÓN

*Métricas, sobreajuste y normalización.*

---

# TABLA DE CONTENIDOS

**01.** INTRODUCCIÓN

**02.** MATRIZ DE  
CONFUSIÓN

**03.** MÉTRICAS

**04.** SOBREAJUSTE

**05.** NORMALIZACIÓN

01

# INTRODUCCIÓN

# INTRODUCCIÓN

---

¿De qué manera puedo medir el desempeño de mi modelo?

Tenemos el error que comete el método, pero :

- ¿Cuántos ejemplos del conjunto de entrenamiento **clasifica correctamente**?
- ¿Cuántos ejemplos que **NO** pertenecen al conjunto de entrenamiento **clasifica correctamente**?
- ¿Qué significa “*clasificar correctamente*”?

# OBJETIVOS

---

01

Evaluar un método de clasificación con **métricas estándar.**

02

Comparar **varios métodos de clasificación** en un mismo dataset

03

Analizar un mismo método de clasificación en **diferentes datasets.**


04

Medir el efecto del **cambio de parámetros** en un método.

# EVALUACIÓN

---

- Dividir el conjunto de datos disponible en
  - Conjunto de Entrenamiento (training set)
  - Conjunto de Prueba (testing set)



Luego, entrenar y evaluar

1. **Entrenar** la red con el conjunto de entrenamiento.
2. **Evaluar** el método con el conjunto de **entrenamiento**.
3. **Evaluar** el método con el conjunto de **prueba**

# EVALUACIÓN

---

1. ¿Cómo sabemos si esta **división es apropiada**?
2. ¿Cómo evaluamos cuantitativamente la **capacidad de clasificación**?
3. ¿Es verdad que si  $\mathbf{E}(\mathbf{w}) \equiv \mathbf{0}$ , entonces es un clasificador perfecto?

# METODOLOGÍAS

---

Matriz de Confusión

Métricas para la evaluación del rendimiento

Diseño del experimento para la evaluación

# 02

## MATRIZ DE CONFUSIÓN

# MATRIZ DE CONFUSIÓN

Tabla que permite evaluar el desempeño de un algoritmo de **clasificación**.

- **Columna** → cantidad de instancias en la clase dada por el método. (Predicción)
- **Fila** → cantidad de instancias en la clase verdadera. (Real/Actual)

|        |          | Prediction |          |
|--------|----------|------------|----------|
|        |          | Positive   | Negative |
| Actual | Positive | TP         | FN       |
|        | Negative | FP         | TN       |

# EJEMPLO

---

Consideremos un modelo de clasificación que fue entrenado para distinguir entre: perros y gatos.

Se toma una muestra de 27 animales:


- 15 perros
- 12 gatos

Después de clasificar se obtiene la siguiente matriz de confusión:

|              | <b>Perro</b> | <b>Gato</b> |
|--------------|--------------|-------------|
| <b>Perro</b> | 11           | 4           |
| <b>Gato</b>  | 2            | 10          |

# MATRIZ DE CONFUSIÓN MULTICLASE

Supongamos  
que tenemos  
**5 clases**



03

MÉTRICAS

# MÉTRICAS

---

Criterios para evaluar la clasificación

Métricas estándar:

- Accuracy
- Precision
- Recall
- F1-Score
- Tasa de TP
- Tasa de FP

# MÉTRICAS

---

## ACCURACY

$$\frac{TP + TN}{TP + TN + FN + FP}$$

## PRECISION

$$\frac{TP}{TP + FP}$$

## RECALL

$$\frac{TP}{TP + FN}$$

## F1-SCORE

$$\frac{2 * precision * recall}{precision + recall}$$

# TASAS

---

**Tasa de Verdaderos Positivos**

$$\frac{TP}{TP + FN}$$

**Tasa de Falsos Positivos**

$$\frac{FP}{FP + TN}$$

# PROCEDIMIENTO

---

Teniendo los dos conjuntos de datos, el de entrenamiento y el de prueba:

Dada una cantidad de épocas: epoch

1. Calcular los **w** utilizando el conjunto de entrenamiento.
2. **Clasificar** los datos del conjunto de prueba utilizando los w encontrados en el paso 1
3. Calcular el valor de las **métricas** para los ejemplos del conjunto de entrenamiento y luego para los del conjunto de prueba.

Realizar el mismo experimento para epoch = 1, 10, 20, . . . , 300

04


---

# SOBREAJUSTE

Overfitting


# DATASET

---




# UNDERFITTING

---



# OVERFITTING

---



# OVERFITTING / SOBREAJUSTE

---

En cualquier método de aprendizaje:


Es el efecto de **sobreentrenar** un algoritmo de aprendizaje con datos para los que se conoce el resultado deseado.

El método clasifica con gran precisión los datos del conjunto de entrenamiento


Pero... **no puede generalizar**

# EJEMPLO ACCURACY


---



# EJEMPLO SOBREAJUSTE



# EJEMPLO SOBREAJUSTE



# CAUSAS

---

El sobreajuste puede deberse a diversos factores:

- Conjunto de datos de entrenamiento **no balanceado**.
- **Pocos registros** en el conjunto de entrenamiento.
- Conjunto de datos de entrenamiento con mucho **ruido**.

# TRAIN/TEST SPLIT

---

¿Cómo sabemos si la partición train/test es apropiada?

Utilizamos métodos de experimentación


**Validación Cruzada (K-Fold Cross Validation)**

*Nota: NO es la única técnica*

# K-FOLD CROSS-VALIDATION

---

1. Se **divide** aleatoriamente el dataset en **k partes** “iguales”.
2. Tomar  $k - 1$  partes y usarlas para entrenar (training\_set) y el remanente como testing\_set



# K-FOLD CROSS-VALIDATION

---


*for  $j=1\dots T$  (generalmente  $T=k$ )*

1. Entrenamiento con el  $j$ -ésimo conjunto
2. Evaluación del método usando como testing set la parte separada para tal efecto.
3. Se calcula alguna medida de la precisión del método.

Finalmente se obtienen parámetros de desempeño del promedio de las  $T$  iteraciones.

# RESUMEN

---



05

# NORMALIZACIÓN

# FEATURE SCALING

---

Se utiliza para escalar los datos dentro un intervalo [a; b]

## MIN-MAX FEATURE SCALING

$$X' = \frac{X - X_{min}}{X_{max} - X_{min}} (b - a) + a$$

Entre [0; 1] sería:

$$X' = \frac{X - X_{min}}{X_{max} - X_{min}}$$

# ESTANDARIZACIÓN

Tomamos las variables del conjunto  $P=\{X_1, ..., X_p\}$ . Cada  $X_i$  tiene  $n$  registros.  
Se calculan los siguientes estadísticos unidimensionales:

## MEDIA

$$\bar{X}_i = \frac{1}{n} \sum_{j=1}^n X_i^j$$

## DESVÍO ESTÁNDAR


$$s_i^2 = \frac{1}{n} \sum_{j=1}^n (X_i^j - \bar{X}_i)$$

## VARIABLE ESTANDARIZADA

$$\tilde{X}_i = \frac{X_i - \bar{X}_i}{s_i}$$


*Nota: También llamada Z-Score*

# EJEMPLO



# EJEMPLO

Si estandarizamos las variables



# UNIT LENGTH SCALING

---

Si bien todas las anteriores son formas de normalización de datos, se le suele llamar “normalizar” o unit length scaling a dividir por la norma 2:

## UNIT LENGTH SCALING

$$X' = \frac{X}{||X||}$$