Sistemas de Inteligencia Artificial: TP4

Métodos de Aprendizaje NO Supervisado

1. Campañas de marketing.

Una agencia de marketing trabaja con creadores de contenido en redes sociales para difundir las propuestas de sus clientes. Actualmente, los selecciona principalmente por su cantidad de seguidores pero notaron que las campañas comerciales no generan ingresos suficientes para recuperar la inversión. Si bien las publicaciones tienen visibilidad, no llegan al público al que están dirigidos los productos.

Entre sus principales clientes se encuentran refugios que promueven la adopción de perros, marcas de ropa de entrenamiento para fútbol, empresas de productos de belleza y comercios de materiales de arte. Cada cliente necesita llegar a una audiencia diferente y comunicar su propuesta mediante contenido adecuado. En el caso de los refugios, el objetivo es impulsar las consultas y adopciones, en los demás rubros aumentar las ventas.

Frente a esta situación, la agencia busca mejorar la selección de creadores de contenido considerando, en conjunto, el perfil comercial de cada creador, las características de su audiencia y el contenido que publica.

Para ello, se cuenta con un catálogo de creadores de contenido en redes sociales en `datos/creadores.csv`. Cada fila representa un creador de contenido en redes sociales junto con sus variables, medidas a fin de mes:

Variables de `datos/creadores.csv`:

- `creator_id`: Identificador único de cada creador.
- `name`: Nombre de usuario del creador de contenido.
- `followers`: Cantidad de seguidores.
- `average_reach`: Media de cuentas alcanzadas por publicación.

- `average_impressions`: Media de cantidad de veces que se mostró una publicación (incluye visualizaciones repetidas de una misma cuenta, a diferencia del alcance, que contabiliza cuentas únicas).
- `average_video_views`: Media de reproducciones de video por publicación.
- `monthly_posts`: Media de publicaciones por mes.
- `argentina_audience_pct`: Porcentaje de seguidores ubicados en Argentina.
- `estimated_argentina_reach`: Cantidad estimada de cuentas alcanzadas en Argentina, calculada como `average_reach` x `argentina_audience_pct` / 100.
- `non_follower_reach_pct`: Porcentaje del alcance proveniente de cuentas que no siguen al creador.
- `likes_per_1000`: Promedio de la cantidad de *likes* por cada 1.000 cuentas alcanzadas.
- `comments_per_1000`: Promedio de la cantidad de comentarios por cada 1.000 cuentas alcanzadas.
- `saves_per_1000`: Promedio de la cantidad de veces que se guardó el contenido por cada 1.000 cuentas alcanzadas.
- `shares_per_1000`: Promedio de la cantidad de veces que se compartió el contenido por cada 1.000 cuentas alcanzadas.
- `total_engagement_per_1000`: Suma de `likes_per_1000`, `comments_per_1000`, `saves_per_1000` y `shares_per_1000`.
- `profile_visits_per_1000`: Visitas al perfil generadas por cada 1.000 cuentas alcanzadas.
- `price_usd`: Cotización en USD por una publicación patrocinada.
- `price_ars`: Cotización equivalente en pesos argentinos, calculada con un tipo de cambio fijo a fin de mes de 1 USD = 1.500 ARS.
- `sponsored_posts_pct`: Porcentaje de publicaciones patrocinadas.
- `organic_posts_pct`: Porcentaje de publicaciones orgánicas (no patrocinadas).
- `topic_football_pct`: Porcentaje de publicaciones cuya temática principal es fútbol.
- `topic_makeup_pct`: Porcentaje de publicaciones cuya temática principal es maquillaje.
- `topic_dogs_pct`: Porcentaje de publicaciones cuya temática principal es perros.
- `topic_art_pct`: Porcentaje cuya temática principal es arte.

- `content_tutorial_pct`: Porcentaje de publicaciones que explican un procedimiento por medio de un tutorial.
- `content_review_pct`: Porcentaje de publicaciones que evalúan una experiencia o producto por medio de una reseña.
- `content_entertainment_pct`: Porcentaje de publicaciones cuyo propósito principal es entretener.
- `content_showcase_pct`: Porcentaje de publicaciones que muestran productos o resultados.
- `average_caption_words`: Media de palabras del texto que acompaña cada publicación.
- `average_watch_time_seconds`: Tiempo medio de reproducción, expresado en segundos.
- `video_posts_pct`: Porcentaje de publicaciones que incluyen al menos un video (puede superponerse con cualquier temática o tipo de contenido)
- `short_form_posts_pct`: Porcentaje de publicaciones en formato de 'short' o breve.
- `trend_posts_pct`: Porcentaje de publicaciones que participan de tendencias recientes.

1. **Exploración y representación.**
   Analizar el conjunto de datos y seleccionar qué variables serán utilizadas para resolver el problema. Para ello, se debe realizar un Exploratory Data Analysis (EDA) y un **Análisis de Componentes Principales (PCA)**. Justificar si se realiza una reducción de dimensionalidad y cómo se interpretan las componentes.

2. **Implementación**
   Implementar una red de **Kohonen** con el objetivo de agrupar los creadores de contenido en términos de todas sus variables. Como parte del análisis se deberá como mínimo:

   - Variar los hiperparámetros correspondientes a la red y justificar la elección final evaluando la performance del modelo.
   - Analizar la grilla de neuronas y la distribución de los creadores de contenido en la misma y analizar la Matriz U.
   - Interpretar los resultados para el caso de uso. Por ejemplo, ¿Qué perfiles de creadores reúne cada región de la grilla seleccionada? ¿Coinciden con los perfiles observados en la PC1 y PC2 (biplot)? ¿Qué indica una distancia alta entre neuronas vecinas en la matriz U?

3. **Índice**

   Implementar la regla de **Oja** sobre los mismos datos para generar un índice de creadores de contenido y analizarlo. Por ejemplo, ¿qué representa este índice? ¿Cómo se puede interpretar? ¿Sería correcto elegir automáticamente al creador con el valor más alto para cualquier campaña?

   Comparar el resultado con la proyección sobre PC1 obtenida mediante PCA.

4. **Decisión para las campañas.**

   A lo largo de todo el trabajo se deben interpretar los resultados obtenidos y en base a la evidencia tomar decisiones para las campañas de marketing de los clientes de la agencia.

   Preguntas dispadoras de ejemplo:

   - Para una campaña de fútbol, ¿conviene priorizar alcance masivo, descubrimiento o profundidad educativa? Fundamentar la elección según los resultados obtenidos previamente.
   - Comparar la selección obtenida con una estrategia basada únicamente en `followers`. ¿Qué ventajas y/o desventajas tiene cada estrategia?
   - ¿Qué implica el manteniemiento del sistema desarrollado? ¿qué ocurre cuando llega a la agencia una nueva campaña? ¿Qué cambios serían necesarios en caso de tener que actualizar la cantidad de creadores de contenido o se desean incorporar nuevas variables? ¿Qué implicancias tiene la actualización de los datos de los creadores de contenido a fin de cada mes?

   Aclaración: El foco del ejercicio está en los métodos de aprendizaje no supervisado y en la interpretación de los resultados obtenidos. No se espera que se realice un análisis de marketing exhaustivo y se pueden asumir ciertos supuestos sobre las features si es necesario.

2. Memoria asociativa

El objetivo de este ejercicio es estudiar la recuperación de información a partir de patrones incompletos o ruidosos mediante una red de **Hopfield**.

2.1. Recuperación de códigos QR deteriorados

Estás de vacaciones en Italia y después de un largo día de recorrido decidís ir a almorzar a la *'Trattoria Aurora'*, un restaurante del pueblo muy reconocido por su excelente gastronomía. Al sentarte ves un código QR impreso sobre la mesa y lo escaneás para ver el menú. Notás que

una de sus esquinas está rota impidiendo que puedas escanearlo. Mirando a las otras mesas te das cuenta que no se renuevan hace tiempo: papeles desgastados, rayados, manchados con comida o rasgados.

Decidís ir a hablar con quien esté a cargo y te atiende la misma 'Aurora', dueña del restaurante. Te comenta que el restaurante tiene cinco cartas digitales diferentes, cada una con su propio código QR: menú principal, vinos, cócteles y otras bebidas, postres y especiales del día. Con el uso, los códigos QR se deterioran rápidamente y ya se cansaron de invertir en renovarlos.

Rápidamente se te ocurre una idea: implementar un sistema de memoria asociativa con una red de Hopfield que permita recuperar los códigos QR deteriorados y enviarlos a un lector de QR para que pueda decodificarlos.

En la carpeta 'datos/hopfield' se encuentran los códigos QR originales que redirigen a cada menú:

- Representar cada uno mediante una matriz binaria de 37×37 (Aclaración: a fines del TP se utilizarán tamaños de imágenes pequeños debido al costo computacional y al preprocesamiento de las imágenes)
- Almacenar los cinco vectores en la red y construir patrones de consulta.
- Analizar la alteración de los códigos QR mediante la adición de ruido aleatorio con disitnitos niveles de ruido, simulando el deterioro de los mismos.
- Analizar la cantidad de iteraciones y la energía en cada paso de la red.
- Explicar las limitaciones del caso de uso.

Food
https://github.com/eugepineiro/sia-tips/blob/feature/tp4-images/TPs/TP4/food_menu.png

Wine
https://github.com/eugepineiro/sia-tips/blob/feature/tp4-images/TPs/TP4/wine_menu.png

Beverages
https://github.com/eugepineiro/sia-tips/blob/feature/tp4-images/TPs/TP4/beverages_menu.png

Dessert
https://github.com/eugepineiro/sia-tips/blob/feature/tp4-images/TPs/TP4/dessert_menu.png

Specials
https://github.com/eugepineiro/sia-tips/blob/feature/tp4-images/TPs/TP4/specials_menu.png

2.2. Recomendación

Se recomienda primero probar el funcionamiento de la red con un caso de uso más sencillo antes de pasar al caso de imágenes.

Construir patrones de letras del abecedario utilizando 1 y -1 y matrices de 5×5. Por ejemplo, con la matriz

$$\begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ -1 & -1 & -1 & 1 & -1 \\ -1 & -1 & -1 & 1 & -1 \\ 1 & -1 & -1 & 1 & -1 \\ 1 & 1 & 1 & -1 & -1 \end{pmatrix}$$

puede dibujarse la letra J:

```
* * * * *
      *
      *
*     *
* * *
```

1. Almacenar 4 patrones de letras. Implementar el modelo de Hopfield para asociar matrices de 5×5 con los patrones de las letras almacenadas.

2. Relizar un análisis de ortogonalidad y de la capacidad de almacenamiento de la red.

3. Ingresar un patrón muy ruidoso e identificar un estado espúreo.